Analisis Sentimen Jokowi di Media Sosial Twitter

1119003 Levin Martinus
1119005 Aristo Demos
1119006 William Juniar
1119007 Timothy Ray
1119009 Julian Ely
1119011 Andreas Virdian

TABLE OF CONTENTS









Dataset

Dataset yang digunakan didapatkan melalui Twitter API dengan kata kunci "jokowi". Hasilnya didapat sebanyak 277 tweet berbahasa Indonesia yang diambil dari tanggal 20 Februari 2022 sampai tanggal 23 Februari 2022. Tweet tersebut disimpan dalam ekstensi file .csv.

	Unnamed: 0	id	text	created_at
0	0	1495415872164229120	RT @LurahIstana: Jokowi sudah mengesahkan pera	2022-02-20T15:11:42.000Z
1	1	1495415869673177090	RT @NabilaAr: Kami para santri sangat tepat	2022-02-20T15:11:41.000Z
2	2	1495415863377539074	RT @Sangkuriang5551: FOKUS KE JOKOWII\n\nMasal	2022-02-20T15:11:39.000Z
3	3	1495415855546798083	RT @jokowi: Srikandi-srikandi bulutangkis putr	2022-02-20T15:11:38.000Z
4	4	1495415849015930880	RT @CasanovaX8X: LOMBOK #MandalikaCircuit\n#Jo	2022-02-20T15:11:36.000Z
5	5	1495415838991859713	RT @geloraco: BPJS Kesehatan Jadi Syarat Jual	2022-02-20T15:11:34.000Z
6	6	1495415827960516623	RT @KangUtang04: #JokowiTheRealDictator \n#Jok	2022-02-20T15:11:31.000Z
7	7	1495415826912264194	RT @kompascom: Hasil 71 persen tersebut merupa	2022-02-20T15:11:31.000Z
8	8	1495415825309724675	RT @LurahIstana: Jokowi sudah mengesahkan pera	2022-02-20T15:11:30.000Z
9	9	1495415817768300546	RT @OposisiCerdas: Tidak Hanya Jual-beli Tanah	2022-02-20T15:11:29.000Z
10	10	1495415816275505155	RT @CNNIndonesia: Survei Indikator: 70 Persen	2022-02-20T15:11:28.000Z

Tweet Extraction - Initialization

Dataset tersebut diekstraksi dengan menggunakan API Twitter.

Pertama, BEARER_TOKEN harus diisi terlebih dahulu. BEARER_TOKEN akan diberikan secara rahasia saat kita membuat akun Twitter Developer Platform di developer.twitter.com.

Fungsi bearer_oauth bertujuan untuk melakukan authorization dari token yang sudah diisi.

Kemudian, fungsi create_url akan menciptakan url tujuan beserta query, max. Results, dan field-field yang dibutuhkan untuk menampung data ekstraksi

Fungsi connect_to_endpoint bertujuan menghubungkan dengan endpoint yang dituju beserta status dari response tersebut

```
BEARER_TOKEN = ''
```

```
def bearer oauth (r):
   r.headers['Authorization'] = f"Bearer {BEARER TOKEN}"
   r.headers['User-Agent'] = "v2RecentSearchPython"
   return r
def create url(keyword, max results=10):
   search url = 'https://api.twitter.com/2/tweets/search/recent'
    query params = {
        'query': keyword,
        'max results': max results,
        'tweet.fields': 'id, text, created at, lang',
        'next token': {}
   return (search url, query params)
def connect to endpoint(url, params, next token=None):
   params['next token'] = next token
   response = requests.get(url, auth=bearer oauth, params=params)
   print("Endpoint Response Code: " + str(response.status code))
   if response.status code != 200:
       raise Exception(response.status code, response.text)
   return response.json()
```

Tweet Extraction - Query

Setelah fungsi-fungsi dibuat, maka dicantumkan apa yang ingin kita lakukan dengan API. Dalam pengambilan data tweet, cantumkan keyword beserta max_results (berapa banyak).

Lalu, cantumkan kedua data tersebut sebagai parameter dalam membuat url.

Setelah url dibuat, lakukan koneksi dengan endpoint tersebut dan hasilnya akan disimpan ke dalam format JSON seperti gambar di samping.

```
url = create url(keyword, max results)
json response = connect to endpoint(url[0], url[1])
print(json.dumps(json response, indent=4))
Endpoint Response Code: 200
    "data": [
            "lang": "in",
            "id": "1496442669786341379",
            "text": "RT @SantorinisSun: Aslinya orang akan semakin keliatan di ujung biasanya\ude31\nhttps://t.co/3
Tfk2L9s4V",
            "created at": "2022-02-23T11:11:49.000Z"
            "lang": "und",
            "id": "1496442664539013120",
            "text": "RT @dipoyono suro: @jokowi @JuanSet92625846 https://t.co/0P4XwyCRrm",
            "created at": "2022-02-23T11:11:48.000Z"
            "lang": "in",
            "id": "1496442662010114050".
```

```
keyword = "jokowi"
max_results = 100
```

Tweet Extraction - Storing Data

Setelah data berhasil diambil dengan melakukan koneksi terhadap endpoint, data dimasukkan ke dalam variabel df sebagai data frame.

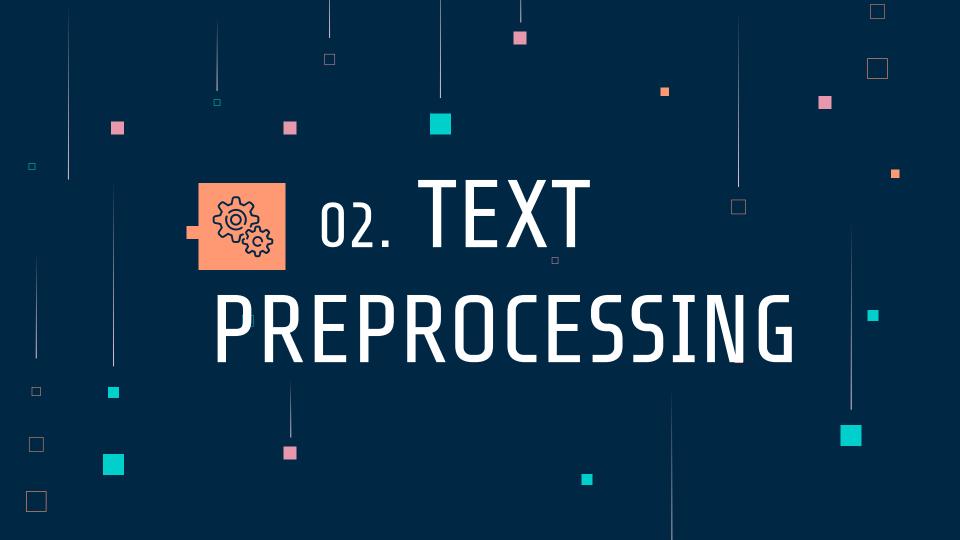
Data akan di-filter untuk memilih tweet yang berbahasa Indonesia saja.

Kemudian hasil extraction akan disimpan ke dalam sebuah file csv bernama "jokowi_twitter_sentiment.csv" agar data lebih mudah diolah.

```
df = pd.DataFrame(json response['data'])
```

```
df_filtered = df[df['lang'] == 'in'].drop('lang', axis=1)
df_filtered
```

	(222)	8	(612)		
95	1496442136132452360	RT @CNNIndonesia: "Kalau publik enggak ribut,	2022-02- 23T11:09:42.000Z		
96	1496442134698020865	RT @djaritakirana: Terus kawal kasus duo terdu	2022-02- 23T11:09:42.000Z		
97	1496442132844134404	RT @OposisiCerdas: Soroti Kinerja Jokowi, Riza	2022-02- 23T11:09:41.000Z		
98	1496442127999733766	RT @dennysirregar7: Mau muntah gua \n\nhttp	2022-02- 23T11:09:40.000Z		
99	1496442120005369859	RT @nafikulla: @jokowi betul pak, msyrkat yg k	2022-02- 23T11:09:38.000Z		
92 rows × 3 columns					
df_filtered.to_csv('jokowi_twitter_sentiment.csv', mode='a')					



Data Cleaning

Pertama-tama, file jokowi_twitter_sentiment.csv dibaca menggunakan pandas dalam bentuk tabel data.

Kemudian, file jokowi_twitter_sentiment_label ed.txt dimasukkan ke tabel tersebut dalam kolom label.

Lalu, data yang kolom textnya terduplikat akan dibuang dari tabel data.

```
1 df = pd.read_csv('jokowi_twitter_sentiment.csv')
```

```
with open('jokowi_twitter_sentiment_labeled.txt', 'r') as file:
label = file.read().splitlines()
df['label'] = label
df
```

Drop duplicate

```
clean_df = df[df['text'].duplicated()==False]
clean_df.reset_index(inplace=True)
clean_df
```

Manual Labelling

id	text	created_at	label
1495415872164229120	RT @Lurahlstana: Jokowi sudah mengesahkan pera	2022-02-20T15:11:42.000Z	Positive
1495415869673177090	RT @NabilaAr: Kami para santri sangat tepat	2022-02-20T15:11:41.000Z	Positive
1495415863377539074	RT @Sangkuriang5551: FOKUS KE JOKOWI!\n\nMasal	2022-02-20T15:11:39.000Z	Negative
1495415855546798083	RT @jokowi: Srikandi-srikandi bulutangkis putr	2022-02-20T15:11:38.000Z	Positive
1495415849015930880	RT @CasanovaX8X: LOMBOK #MandalikaCircuit\n#Jo	2022-02-20T15:11:36.000Z	Neutral

Pemberian label Positive, Negative atau Neutral dilakukan secara manual dengan mengecek tweet di dataset. Label tersebut tersimpan di file jokowi_twitter_sentiment_labeled.txt.

Manual Labelling

Dari hasil manual labelling, sebanyak 94 data termasuk dalam sentimen negatif, 62 sentimen positif, dan 50 netral.

```
1 data['manual_label'].value_counts()

Negative 94
Positive 62
Neutral 50
Name: manual_label, dtype: int64
```

```
plt.figure()
    plt.hist(data['manual label'])
    plt.show()
80
60
40
20
  Positive
                         Negative
                                                 Neutral
```

Negation words

```
# negation words, negate the sentiment value
with open('negation.txt', 'r') as file:
negation = file.read().splitlines()
```

Booster words

```
# booster words, add more value to sentiment word
with open('booster.txt', 'r') as file:
    booster = file.read().splitlines()
booster = [sent.split() for sent in booster]
booster_words = [row[0] for row in booster]
```

Sentiment words

```
# sentiment words with value range -5 to 5
with open('sentiment_value.txt', 'r') as file:
    sentiment_valued = file.read().splitlines()
sentiment_valued = [sent.split() for sent in sentiment_valued]
sentiment_valued_words = [row[0] for row in sentiment_valued]
```

Pemberian label secara lexicon/rule-based menggunakan 3 jenis kata penting:

Negation words: daftar kata negasi seperti tidak, sulit, jangan dan lainnya. Kata ini mengubah nilai sentimen dari positif (+) menjadi negatif (-) dan sebaliknya.

Booster words: daftar kata tambah seperti sangat, agak, lebih dan lainnya. Kata ini memberikan bobot tambahan ke nilai sentimen antara -2 sampai 2.

Sentiment words: daftar kata yang mengandung sentimen positif dan sentimen negatif dengan pemberian bobot -5 sampai 5.

Pemrosesan data teks memerjukan filter:

Stopwords: kata umum yang sering muncul dan dianggap tidak memiliki makna. Kata ini disaring kembali agar kata penting tidak ikut terhapus.

Noise words: kata-kata yang tidak jelas, seperti salah ketik/typo. 🗆

Slang words: kata gaul/singkatan/musiman yang kemudian diubah menjadi bentuk kata baku.

Stopwords

```
stopwords = set(nltk.corpus.stopwords.words('indonesian'))

# filter stopwords if exist in segmentations, negation, booster
stopwords_copy = stopwords.copy()
for word in stopwords_copy:
    if word in negation or word in booster_words or word in sentiment_valued_words:
        stopwords.discard(word)
```

Noise words

```
# noise words, unnecessary words after folding
with open('noise.txt', 'r') as file:
noise = file.read().splitlines()
```

Slang words

```
# slang words
slang = pd.read_csv('slang.csv')
slang_list = slang.to_numpy(dtype='str')
```

```
def unslang_word(word):
    if word not in slang_list[:,0]:
        return [word]

index = slang_list[:,0].tolist().index(word)
new_word = slang_list[index,1]

return [w for w in new_word.split()]
```

```
word dict = {}
processed tweets = []
for tweet in tweets:
    # sentence seamentation
    sentences = nltk.tokenize.sent_tokenize(tweet)
    new words = []
    for sentence in sentences:
        # punctuations and numbers to be removed, '@' to identify mentioned user, '-' to identify sentiment word
        remove = string.punctuation.replace('@','').replace('-','')+'"'+'0123456789'
        # replace word, remove non ASCII, remove punctuation, remove number, remove whitespaces, to lower
        folded = sentence.replace('&amp','&').replace('\n',' ').replace('\n',' ').replace('RT','').replace('minyak goreng','mi
nyak-goreng').encode('ascii','ignore').decode('ascii').translate(str.maketrans('','',remove)).strip().lower()
        # word tokenizing
        words = nltk.word tokenize(folded)
        isUser = False
        for word in words:
            # remove mentioned user
            # the next word after '@' will be user
            if isliser:
                isUser = not isUser
                continue
            if word == '@':
                isUser = not isUser
                continue
            # remove url.
            if word.startswith('htt'):
                continue
```

Text Normalization

- Menghapus punctuation
- Mengubah kata menjadi lowercase
- Menghapus angka
- Menghapus spasi
- Mengganti beberapa kata dan simbol
- Menghapus mention
- Menghapus "RT"
- Menghapus noise
- Mengubah kata qaul/singkatan/musiman

```
37
                # remove noise
                if word in noise:
38
                    continue
39
40
41
                # normalize slang word
42
                for new word in unslang word(word):
43
                    # stopword removal
44
                     if new word in stopwords:
45
46
                         continue
47
                    # add processed word
48
                     new_words.append(new_word)
49
                    if new word in word dict.keys():
50
51
                         word dict[new word] += 1
                     else:
52
53
                         word dict[new word] = 1
54
        processed tweets.append(new words)
55
56
   processed tweets
```

Hasil dari kata yang sudah dinormalisasi

```
[['jokowi',
  'mengesahkan',
  'peraturan',
  'wajib',
  'badan',
  'penyelenggara',
  'jaminan',
  'sosial',
  'diterapkan',
  'aspek',
  'baik',
  'pengurusan',
  'surat',
  'surat'],
 ['santri',
  'sangat',
  'memilih',
  'erick',
  'thohir',
  'penerus',
  'presiden',
  'jokowi',
  'indonesia'
```

Bag of words

```
1 word dict
{'jokowi': 107,
 'mengesahkan': 1,
 'peraturan': 1,
 'wajib': 3,
 'badan': 15,
 'penyelenggara': 8,
 'jaminan': 8,
 'sosial': 7,
 'diterapkan': 1,
 'aspek': 1.
 'baik': 3,
 'pengurusan': 1,
 'surat': 6,
 'santri': 1,
 'sangat': 4,
 'memilih': 1,
 'erick': 3,
 'thohir': 3,
 'penerus': 1,
 'presiden': 29,
 'indonesia': 25,
```

```
def sentiment labelling(words):
        val = 0
        for i in range(len(words)):
            sentiment val = 0
            # check if the word is sentiment word
            if words[i] in sentiment valued words:
                sentiment_val = int(sentiment_valued[sentiment_valued_words.index(words[i])][1])
10
11
                # check if the word before is a booster
12
                boosterBefore = False
13
                if i > 0:
14
                   if words[i-1] in booster_words:
15
                        boosterBefore = True
16
17
                        # if sentiment positive then add, if sentiment negative then substract
18
                        if sentiment val > 0:
19
                            sentiment_val += int(booster[booster_words.index(words[i-1])][1])
20
                        elif val < 0:
21
                            sentiment_val -= int(booster[booster_words.index(words[i-1])][1])
22
23
                # check if the word after is a booster
24
                if i < len(words)-1:
25
                   if words[i+1] in booster words:
26
27
                        # if sentiment positive then add, if sentiment negative then substract
                        if sentiment val > 0:
29
                            sentiment val += int(booster[booster words.index(words[i+1])][1])
30
                        elif val < 0:
31
                            sentiment_val -= int(booster[booster_words.index(words[i+1])][1])
32
                # check if the word before the booster is a negation
                if boosterBefore and i > 1:
34
                    if words[i-2] in negation:
                        sentiment val *= -1
                # if word before is not booster, check if the word before is a negation
                elif words[i-1] in negation:
                    sentiment_val *= -1
42
            val += sentiment_val
        return val
```

```
sentiment_values = [sentiment_labelling(words) for words in processed_tweets] print(sentiment_values)

[5, -1, -6, 0, 0, -2, -8, 3, 1, 2, -8, -2, -8, 1, 1, 2, 2, 2, 0, -1, -1, 4, -2, -4, 4, -2, 5, 0, 0, 1, 1, 0, -1, -5, -8, 3, 1, -2, 0, 0, 6, 2, -3, -3, -2, -5, -6, 0, 0, 0, -8, 0, 0, -2, 0, 2, -8, -10, 11, 0, 0, 0, 2, 0, 0, 0, 0, 0, -3, -2, 0, 0, 2, 0, 0, -4, 0, -2, 2, 2, -2, -2, -3, 2, -3, 7, 1, 0, 0, 0, -1, 1, 0, -2, 2, 0, -4, -3, 2, 4, -7, 5, 2, 0, 0, 0, 0, 0, -5, -2, -2, -1, 4, 1, 0, -2, -3, 0, -7, 3, -2, 4, 2, -2, 0, 7, 5, 1, -4, 0, -2, 0, -4, -5, -1, 0, 2, -3, 0, -4, 0, -2, -2]
```

```
def classify_value(value):
    if value > 0:
        return 'Positive'
    elif value == 0:
        return 'Neutral'
    else:
        return 'Negative'
```

Data teks yang ternormalisasi akan diberikan nilai sentimen dengan memperhatikan kata sentimen, kata tambah sebelum dan sesudah kata sentimen, dan kata negasi sebelum kata sentimen.

Nilai sentimen diubah menjadi label "Positive" untuk nilai > 0, label "Neutral" untuk nilai = 0, dan label "Negative" untuk nilai < 0.

Dari hasil lexicon labelling, sebanyak 80 data termasuk dalam sentimen negatif, 68 sentimen positif, dan 58 netral.

```
1 data['lexicon_label'].value_counts()

Negative 80

Neutral 68

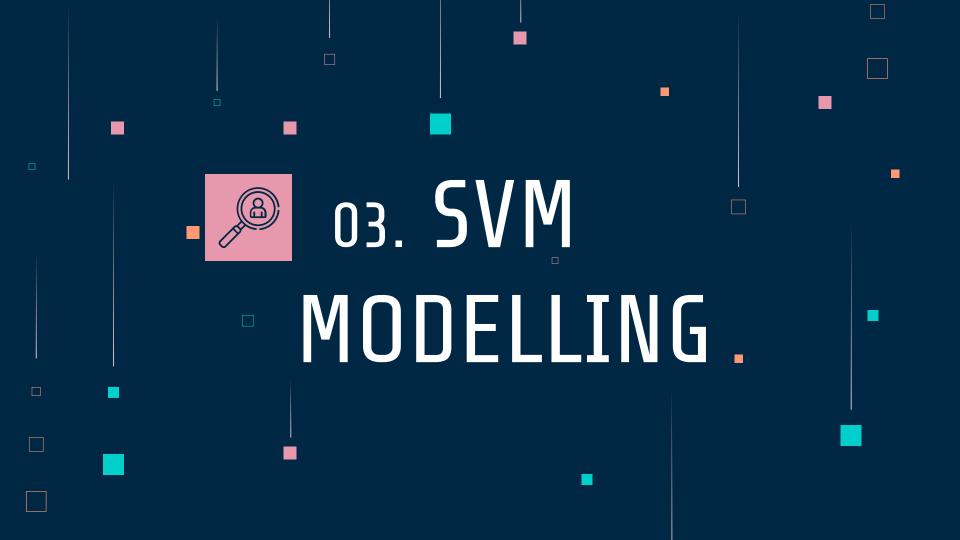
Positive 58

Name: lexicon_label, dtype: int64
```

```
plt.figure()
    plt.hist(data['lexicon label'])
    plt.show()
80
70
60
50
40
30
20
10
  Positive
                         Negative
                                                  Neutra
```

Perbandingan Jumlah Positive, Negative dan Neutral manual_label dengan lexicon_label

```
plt.hist([data['manual_label'], data['lexicon_label']], label=['manual', 'lexicon'])
    plt.legend()
    plt.show()
                                              manual
                                              exicon
                                                              Cara manual menghasilkan
                                                              sentimen positif dan negatif yang
                                                              lebih banyak dibandingkan lexicon,
60
                                                              tetapi lexicon lebih banyak
                                                              menghasilkan sentimen netral
20
  Positive
                        Negative
                                                Neutral
```



SVM Modelling pada Lexicon Label

Membuat model diawali dengan membagi antara data training dan data testing

Komposisi yang kami gunakan adalah 80% training dan 20% testing, kemudian akan dimasukkan ke dalam data frame baru, lexicon_df_train80 dan lexicon_df_train20

```
lexicon_train_X, lexicon_test_X, lexicon_train_Y, lexicon_test_Y = model_selection.train_test_split(data['tweet'], data['lexicon_label'], test_size = 0.2, random_state = 0)
```

```
lexicon_df_train80 = pd.DataFrame()
lexicon_df_train80['tweet'] = lexicon_train_X
lexicon_df_train80['lexicon_label'] = lexicon_train_Y

lexicon_df_test20 = pd.DataFrame()
lexicon_df_test20['tweet'] = lexicon_test_X
lexicon_df_test20['lexicon_label'] = lexicon_test_Y
```

TF-IDF lexicon labelling

Hasil TF-IDF dari lexicon labelling

```
# TF-IDF

from sklearn.feature_extraction.text import TfidfVectorizer

lexicon_tfidf_vect_8020 = TfidfVectorizer(max_features = 5000)

lexicon_tfidf_vect_8020.fit(data['tweet'])

lexicon_train_X_tfidf_8020 = lexicon_tfidf_vect_8020.transform(lexicon_df_train80['tweet'])

lexicon_test_X_tfidf_8020 = lexicon_tfidf_vect_8020.transform(lexicon_df_test20['tweet'])
```

Hasil TF-IDF lexicon manual dan testing

```
print(lexicon train X tfidf 8020)
  (0, 1047)
                0.25796689169680226
  (0, 743)
                0.22626075585226202
  (0, 711)
                0.38910924001544345
  (0, 654)
                0.25796689169680226
  (0, 471)
                0.45252151170452404
  (0, 414)
                0.2394199911849753
  (0, 377)
                0.07811620323624119
  (0, 357)
                0.2394199911849753
  (0, 338)
                0.2965633657027805
  (0, 332)
                0.25796689169680226
  (0, 132)
                0.25796689169680226
  (0, 113)
                0.22626075585226202
  (0, 21)
                0.25796689169680226
  1, 980)
                0.3673969731176012
```

```
print(lexicon test X tfidf 8020)
  (0, 968)
                0.18379737951971664
  (0, 804)
                0.21983825902084567
  (0, 607)
                0.6023531103123709
  (0, 548)
                0.25064440424955425
  (0, 520)
                0.21983825902084567
  (0, 477)
                0.21983825902084567
  (0, 470)
                0.21983825902084567
  (0, 446)
                0.16109431039727098
  (0, 440)
                0.19496676604082638
  (0, 411)
                0.25064440424955425
  (0, 377)
                0.07589884536577327
  (0, 339)
                0.21983825902084567
  (0, 321)
                0.25064440424955425
  (0, 117)
                0.25064440424955425
```

Pembuatan model Support Vector Machine untuk lexicon labelling

```
SVM
In [39]: from sklearn.svm import SVC
         lexicon model = SVC(kernel='linear')
         lexicon model.fit(lexicon train X tfidf 8020,lexicon train Y)
Out[39]: SVC(kernel='linear')
In [40]: from sklearn.metrics import accuracy score
         lexicon predictions SVM 8020 = lexicon model.predict(lexicon test X tfidf 8020)
         lexicon test prediction 8020 = pd.DataFrame()
         lexicon test prediction 8020['Sentiment'] = lexicon test X
         lexicon test prediction 8020['Label'] = lexicon predictions SVM 8020
         lexicon SVM accuracy 8020 = accuracy score(lexicon predictions SVM 8020, lexicon test Y)*100
         lexicon SVM accuracy 8020 = round(lexicon SVM accuracy 8020,1)
```

Hasil dari model Machine Learning untuk lexicon labelling

```
lexicon SVM accuracy 8020
Out[42]: 61.9
         Akurasi menggunakan model SVM sebesar 61.9%
In [43]: from sklearn.metrics import classification report
         print ("\nHere is the classification report:")
         print (classification report(lexicon test Y, lexicon predictions SVM 8020))
         Here is the classification report:
                                     recall f1-score
                        precision
                                                         support
             Negative
                             0.67
                                       0.80
                                                  0.73
                                                              20
              Neutral
                             0.44
                                       0.31
                                                 0.36
                                                              13
             Positive
                             0.67
                                       0.67
                                                 0.67
                                                  0.62
                                                              42
             accuracy
                                                  0.59
                             0.59
                                       0.59
                                                              42
            macro avg
         weighted avg
                             0.60
                                       0.62
                                                  0.60
                                                              42
```

SVM Modelling pada Manual Label

Membuat model diawali dengan membagi antara data training dan data testing

Komposisi yang kami gunakan adalah 80% training dan 20% testing, kemudian akan dimasukkan ke dalam data frame baru, manual_df_train80 dan manual_df_train20

```
manual_train_X, manual_test_X, manual_train_Y, manual_test_Y = model_selection.train_test_split(data['tweet'], data['manual_labe
1'], test_size = 0.2, random_state = 0)
```

```
manual_df_train80 = pd.DataFrame()
manual_df_train80['tweet'] = manual_train_X
manual_df_train80['manual_label'] = manual_train_Y

manual_df_test20 = pd.DataFrame()
manual_df_test20['tweet'] = manual_test_X
manual_df_test20['manual_label'] = manual_test_Y
```

TF-IDF manual labelling

Hasil TF-IDF dari manual labelling

```
# TF-IDF

from sklearn.feature_extraction.text import TfidfVectorizer

manual_tfidf_vect_8020 = TfidfVectorizer(max_features = 5000)
manual_tfidf_vect_8020.fit(data['tweet'])
manual_train_X_tfidf_8020 = manual_tfidf_vect_8020.transform(manual_df_train80['tweet'])
manual_test_X_tfidf_8020 = manual_tfidf_vect_8020.transform(manual_df_test20['tweet'])
```

Hasil dari TF-IDF manual training dan testing

```
print(manual train X tfidf 8020)
  (0, 1047)
                0.25796689169680226
  (0, 743)
                0.22626075585226202
  (0, 711)
                0.38910924001544345
  (0, 654)
                0.25796689169680226
  (0.471)
                0.45252151170452404
                0.2394199911849753
  (0, 414)
  (0, 377)
                0.07811620323624119
  (0, 357)
                0.2394199911849753
  (0.338)
                0.2965633657027805
  (0, 332)
                0.25796689169680226
  (0, 132)
                0.25796689169680226
  (0, 113)
                0.22626075585226202
  (0, 21)
                0.25796689169680226
  (1, 980)
                0.3673969731176012
  (1, 862)
                0.4272708447227949
```

```
print(manual test X tfidf 8020)
  (0, 968)
                0.18379737951971664
  (0, 804)
                0.21983825902084567
  (0, 607)
                0.6023531103123709
  (0, 548)
                0.25064440424955425
  (0, 520)
                0.21983825902084567
  (0, 477)
                0.21983825902084567
  (0, 470)
                0.21983825902084567
  (0, 446)
                0.16109431039727098
     440)
                0.19496676604082638
  (0, 411)
                0.25064440424955425
  (0, 377)
                0.07589884536577327
  (0, 339)
                0.21983825902084567
  (0, 321)
                0.25064440424955425
  (0, 117)
                0.25064440424955425
  (0, 77)
                0.20181781927028114
  (1, 918)
                0.25767687200776235
  (1, 900)
                0.23915082287838885
  (1, 698)
                0.22600638183696656
```

Pembuatan model Support Vector Machine untuk manual labelling

```
from sklearn.svm import SVC
manual model = SVC(kernel='linear')
manual model.fit(manual train X tfidf 8020, manual train Y)
SVC(C=1.0, cache size=200, class weight=None, coef0=0.0,
    decision function shape='ovr', degree=3, gamma='auto deprecated',
    kernel='linear', max iter=-1, probability=False, random state=None,
    shrinking=True, tol=0.001, verbose=False)
from sklearn.metrics import accuracy score
manual predictions SVM 8020 = manual model.predict(manual test X tfidf 8020)
manual test prediction 8020 = pd.DataFrame()
manual test prediction 8020['Sentiment'] = manual test X
manual test prediction_8020['Label'] = manual_predictions_SVM_8020
manual SVM accuracy 8020 = accuracy score(manual predictions SVM 8020, manual test Y)*100
manual SVM accuracy 8020 = round(manual SVM accuracy 8020,1)
```

Hasil dari model Machine Learning untuk manual labelling

```
manual SVM accuracy 8020
76.2
Hasil akurasi berbeda dari lexicon label, akurasinya naik menjadi 76.2%
    from sklearn.metrics import classification report
    print ("\nHere is the classification report:")
    print (classification report(manual test Y, manual predictions SVM 8020))
Here is the classification report:
              precision
                            recall f1-score
                                                support
    Negative
                                        0.82
                   0.72
                              0.96
                                                     24
     Neutral
                   1.00
                              0.33
                                        0.50
    Positive
                   0.88
                              0.58
                                        0.70
                                                     12
                                        0.76
                                                     42
    accuracy
                   0.86
                              0.62
                                        0.67
                                                     42
   macro avg
weighted avg
                   0.80
                              0.76
                                        0.74
                                                     42
```

Perbandingan Hasil Manual Label Dengan Lexicon Label

Manual

Here is the o	classification precision		f1-score	support
Negative	0.72	0.96	0.82	24
Neutral	1.00	0.33	0.50	6
Positive	0.88	0.58	0.70	12
accuracy			0.76	42
macro avg	0.86	0.62	0.67	42
weighted avg	0.80	0.76	0.74	42

Lexicon

Here is the c	lassification precision	report: recall	fl-score	support
Negative	0.67	0.80	0.73	20
Neutral	0.44	0.31	0.36	13
Positive	0.67	0.67	0.67	9
accuracy			0.62	42
macro avg	0.59	0.59	0.59	42
weighted avg	0.60	0.62	0.60	42

Machine Learning memiliki akurasi untuk memprediksi sentimen yang dibuat manual lebih baik dari pada memprediksi sentimen yang dibuat berdasarkan lexicon dengan selisih 14%. Cara manual menggunakan pemahaman manusia yang memiliki pemahaman kata yang banyak sehingga pelabelan lebih baik dibandingkan lexicon yang memiliki kamus kata yang terbatas

